Den etiske del af AI502

1. grundlæggende AI-etiske begreber & problemstillinger
2. AI som eksistentiel trussel? Hvorfor/hvorfor ikke?
3. Grundlæggende maskinetik & maskinmetaetik
4. Etisk AI i sundhedsvæsen & militær
5. Etiske problemer vedr. AI & masseovervågning
6. Etiske problemer vedr. AI & paternalistisk lovgivning

Den juridiske del af AI503

Agenter & værdier

Etik definition:
forståelse & løsning af et problem om korrekt afvejning af værdier (med at doget i betragtning)

Grundlæggende analyse af et etisk problem
1. VÆRDIER: hvilke værdier er på spil?
2. MORALSK AGENT: hvem har ansvaret for at vælge rigtigt?
3. MORALSKE PATIENTER: hvem skal der tages hensyn til?

Moralsk Agent
1. kan handle
2. er underlagt forpligtelser
kan fortjene bebrejdelser/ros for sine handlinger

en moralsk patient
1. kan lide skade
2. kan krænkes

det skyldfri valg
det rigtige valg
det rosværdige valg
ikke det samme!

værditeori:
1. Konsekventialisme: kan frembringe udfald hvor en etisk relevant værdi.
2. Pligtisme

Ultimative værdier?
1. velfærd
2. lykkefølelse
3. Økonomisk balance
4. at moralske agenter udvikler & udtrykker en dydig personlighed
5. at moralske patienters rettigheder bliver respekteret
6. Handlinger udført i respekt for en fornuftsgiven Morallov

Kompleks moralsk agent

1. fortolke moralske regler rimeligt ift konteksten
2. Prioritere moralske regler rimeligt ift konteksten
3. tilsidesætte moralske regler rimeligt ift konteksten

AI502

UDGØR KUNSTIG INTELLIGENS EN EKSISTENTIEL TRUSSEL?

AI502 - 25 - 2 - AI som eksistentiel trussel
PDF-dokument · 2,3 MB

AI som en trussel for menneskeheden

Den nationale strategi for AI
Pros/cons af værdier
+ mere/hurtigere hjælp til behandling af borgere
+ bedre informationssøgning
+ udvikling af bedre forretningsmodeller
+ afdækning af administrative fejl
+ afsløring af lovovertrædelser
+ Overvågning af systemer og miljø
– menneskers medforståelse
– menneskers værdighed
– at nogen kan stilles til ansvar for skadevolden
– at borgerne kan forstå offentlig sagsbehandling
– at ingen diskrimineres uretfærdigt pga fordomme
– fremskridt i form af bedre offentlig service og økonomisk vækst

Klassifikation af en trussel
1. omfang (scope): hvor mange etiske patienter berøres negativt
2. sværhedsgrad (Severity): hvor meget påvirkes disse patienter som minimum
3. sandsynlighed (Risk): hvor sandsynligt er scenariet?

eksempel:

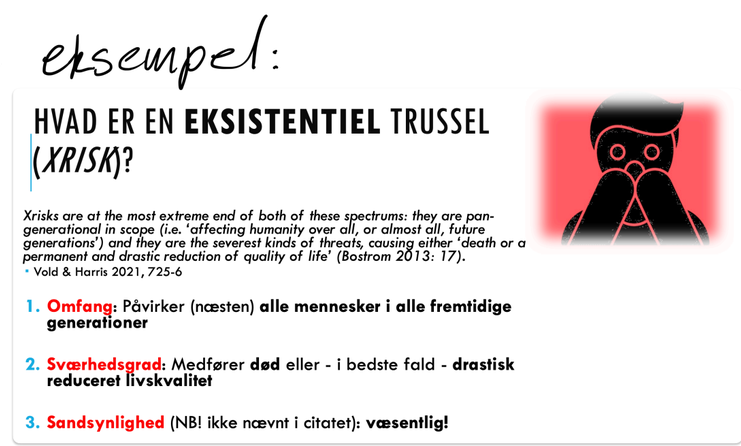
HVAD ER EN EKSISTENTIEL TRUSSEL (XRISK)?

Xrisks are at the most extreme end of both of these spectrums: they are pan-generational in scope (i.e. "affecting humanity over all, or almost all, future generations") and they are the severest kinds of threats, causing either 'death or a permanent and drastic reduction of quality of life' (Bostrom 2013: 17).
- Vold & Harris 2021, 725-6

1. **Omfang:** Påvirker (næsten) **alle mennesker i alle fremtidige generationer**
2. **Sværhedsgrad:** Medfører **død** eller - i bedste fald - **drastisk reduceret livskvalitet**
3. **Sandsynlighed** (NB! ikke nævnt i citatet): **væsentlig!**

Hvad er en væsentlig sansynlighed?

forskellige scenarier

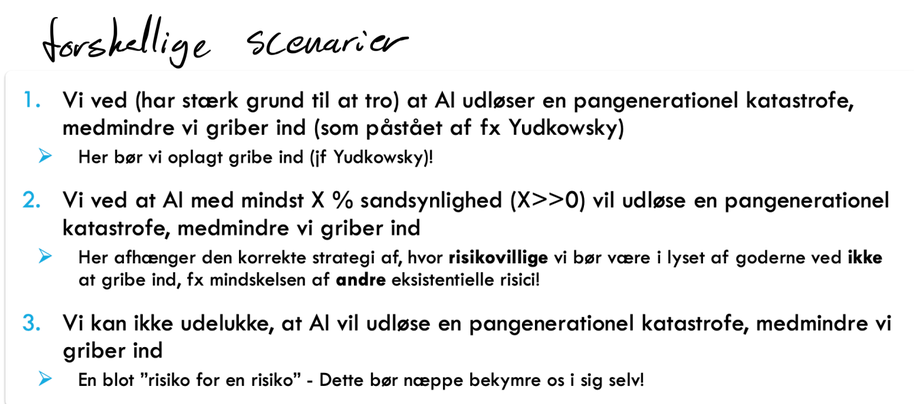
1. Vi ved (har stærk grund til at tro) at AI udløser en pangenerationel katastrofe, medmindre vi griber ind (som påstået af fx Yudkowsky)
   - Her bør vi oplagt gribe ind (jf Yudkowsky)!
2. Vi ved at AI med mindst X % sandsynlighed (X>>0) vil udløse en pangenerationel katastrofe, medmindre vi griber ind
   - Her afhænger den korrekte strategi af, hvor **risikovillige** vi bør være i lyset af goderne ved **ikke** at gribe ind, fx mindskelsen af **andre** eksistentielle risici!
3. Vi kan ikke udelukke, at AI vil udløse en pangenerationel katastrofe, medmindre vi griber ind
   - En blot "risiko for en risiko" - Dette bør næppe bekymre os i sig selv!

Kontrolproblem-argumentet for XRISK (CPAX) af Bostrom (2012)

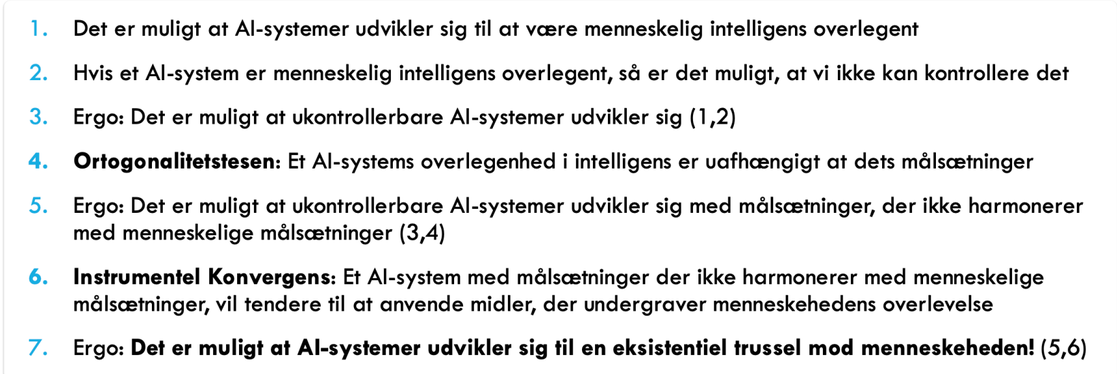
1. Det er muligt at AI-systemer udvikler sig til at være menneskelig intelligens overlegent
2. Hvis et AI-system er menneskelig intelligens overlegent, så er det muligt, at vi ikke kan kontrollere det
3. Ergo: Det er muligt at ukontrollerbare AI-systemer udvikler sig (1,2)
4. **Ortogonalitetstesen:** Et AI-systems overlegenhed i intelligens er uafhængigt at dets målsætninger
5. Ergo: Det er muligt at ukontrollerbare AI-systemer udvikler sig med målsætninger, der ikke harmonerer med menneskelige målsætninger (3,4)
6. **Instrumentel Konvergens:** Et AI-system med målsætninger der ikke harmonerer med menneskelige målsætninger, vil tendere til at anvende midler, der undergraver menneskehedens overlevelse
7. Ergo: **Det er muligt at AI-systemer udvikler sig til en eksistentiel trussel mod menneskeheden!** (5,6)

Midas problemet
det er svært at formulere moralske regler der er:
1. Vejledende i konkrete situationer
2. Undtagelsesløse
3. Uden behov for menneskelig fortolkning

"...most goals that are easy to specify, will not capture the context-specific complexities of human objectives in the real world (V&H 2021)

Maskinetik / Maskinmetaetik

konstruktion af etiske robotter

Den etiske robot
simulere etik (behøver ikke være en moralsk agent)
behøver desuden ikke at simulere etik udenfor sit arbejdsfelt

etiske robotter VS "etiske afstemte" maskiner
opfører en robot sig etisk korrekt eller tager den etiske valg
(en automat opfører sig etisk)

Den kompetente moralske agent
kan sammenligne kontrafaktiske udfald af sine valg
kan fortolke moralske regler rimeligt ift. konteksten
kan prioritere moralske regler rimeligt ift. konteksten
kan begrunde sine valg ud fra relevante moralske regler
kan gøre moralske fremskridt

Robottens handikap ift at simulere en moralsk agent
1. ingen moralske følelser (fx skam, skyld, samvittighed)
2. ingen menneskelig opdragelse

top down
uenighed ift værdier & regler
midasproblemet
perverse instatieringer (virker godt på overfladen men virker ikke i praksis)
ingen fremgang gennem læring.

bottom up
uigennemsigtighed: ingen begrundelse eller forklaring af valg

AI502

•4. Etisk AI i militær og sundhedsvæse

SDU

AI 502 - 25 - 4 - Etisk AI i sundhedsvæsen og militær
Office-præsentation · 11,9 MB

militær & sundhedsvæsen

3 hovedområder
1. Biomedicinsk forskning (benchside)
2. Patient pleje: helbredelse & palliation
3. Folkesundhed: Profylakse, sundhedsøkonomi & epidemistyring (community)

AI med input af omiste data:
Etiske dilemmaer

fordele:
– Precision medicin (precision medicine)
– praktisk implementering af grundforskning (translational medicine)

ulemper:
– skæve datasæt
Potente datasæt i hænderne på regeringer & mægtfulde koncerner
– Misbrug til urimelig diskrimination

AI i patientpleje
1. diagnostik: AI er bedre end mennesker
2. overvågning af patienter & deres medicinering
3. Workflow & hospitalsøkonomi

Den etiske flaskehals
en suboptimal øvre grænse i et etisk problem
eksempel
1. en AI er trænet på en befolkning
2. opererer suboptimalt på minoritet
3. opererer mest effektivt på majoriteten
4. minoritet forringes
5. ny data til AI
osv..

AFIRRM – et ideal for implementering af AI
Adaptivity: regeringsgaranti for trykhed & kontrol
Flexibility: øje for brugssammenhænge
Inclusiveness: borger-inddragelse
Reflexivity: blik for mange typer ricisi
Responsiveness: beredskab ved misbrug & ulykker
Monitoring: opdaterede data

Autonome våbensystemer – Potentielle anvendelsesområder
1. Paramilitært politiarbejde: kontrol af (civil) befolkning
2. forsvar af territorier: Autonom respons på angreb
– neutralisering af missiler/droner
3. angrebskrig

3 hovedargumenter mod Autonome Våbensystemer

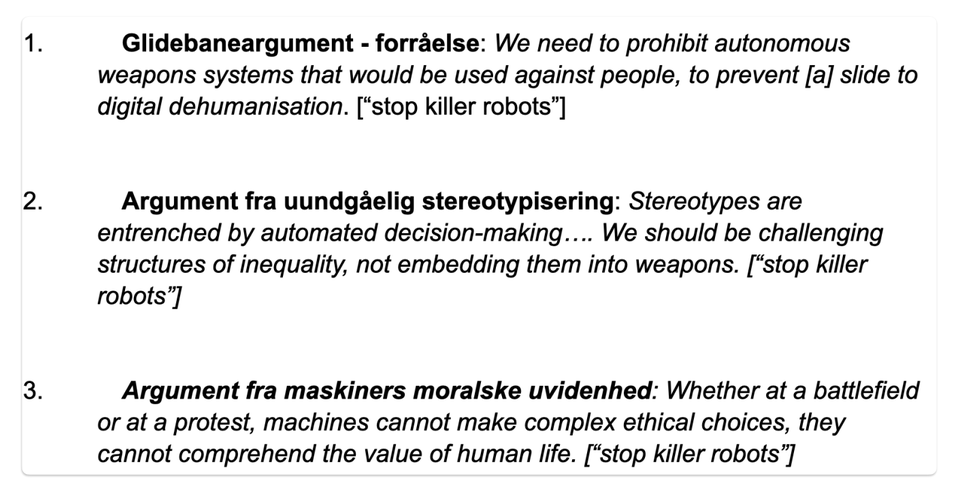
1. **Glidebaneargument - forråelse**: *We need to prohibit autonomous weapons systems that would be used against people, to prevent [a] slide to digital dehumanisation.* ["stop killer robots"]
2. **Argument fra uundgåelig stereotypisering**: *Stereotypes are entrenched by automated decision-making…. We should be challenging structures of inequality, not embedding them into weapons.* ["stop killer robots"]
3. ***Argument fra maskiners moralske uvidenhed***: *Whether at a battlefield or at a protest, machines cannot make complex ethical choices, they cannot comprehend the value of human life.* ["stop killer robots"]

note:
argumenter har stadig en synsvinkel

Argumenter for scholz & Galliotts minimalisme
1. MinAI vil gøre det lettere at holde kombattanter ansvarlige for deres våbenbrug
2. et effektivt mod AI i våben er usandsynligt
derfor bør man implimentere den mest forsigtige form
3. MinAI vil spare ressourcer & menneskeliv
4. Min AI vil sikre bedre proportionallitet i angreb vs legitime militære målsætninger

indvendinger mod scholz & Galliotts minimalisme
1. alle teknologier kan misbruges
2. glidebane. minAI er et lille skridt fra maxAI
3. minAI vil motivere krigsforbrydelser (ansvarsfralæggelse)

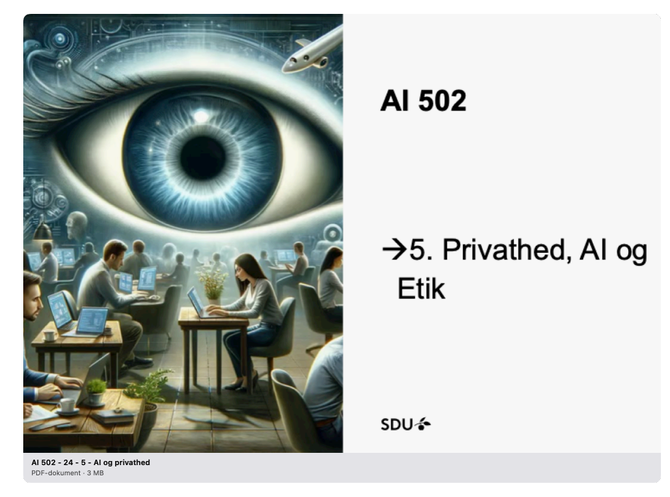
AI 502

→5. Privathed, AI og Etik

SDU

AI 502 - 24 - 5 - AI og privathed
PDF-dokument · 3 MB

følsomme personoplysninger (GDPR)
– Helbred
– Race & Etnisk oprindelse
– Politisk overbevisning
– Religiøs eller filosofiske overbevisning
– fagforeningsmessige tilhørsforhold
– Genetisk data
– Biometrisk data med henblik på entydig identifikation f.eks fingeraftryk eller ansigtsgenkendelse
– Seksuelle forhold/orientering

Privathed
De grundlæggende rettigheder i konflikt
1. Retten til privatliv
2. Retten til hemmeligholdelse
3. Retten til viden - informationsfrihed
4. ytringsfrihed
5. Næringsfrihed
6. Retten til sikkerhed

Rettigheder i et liberalt perspektiv
– Staten har en etisk pligt til at respektere og beskytte individuelle borgeres frihed
– Alle politiske rettigheder falder her under frihedsrettigheder

Relevante former for frihed & negativ frihed
(handler om forholdet mellem hensigt & handling)
– negativ frihed
* ingen ydre forhindring af realisering af hensigt
– Bevidst negativ frihed
* viden om mængde af ydre forhindring af realisering af hensigt
* man ved hvad man kan & ikke kan

Relevante former for frihed & positiv frihed
(handler om forholdet mellem person & hensigt)
– Autonomi som selvstyre:
* min hensigt er udtryk for min særlige, personlige vurdering af en situation
– Autonomi som selvtilstrækkelighed:
* min hensigt er suverænt dannet indefra

personlighed → Hensigt → Handling

Positiv frihed
Personlighed kommer til ordre
Hvad jeg vil, udtrykker hvem jeg er.

negativ frihed
ingen ydre forhindringer
"Jeg kan gøre hvad jeg vil"

Værdien af negativ frihed
1. værdi for den enkelte borger
– kan tilfredsstille sine præferencer, givet ressourcer og motivation
2. Værdi for samfundet
– Borgerne kan uhindret bruge deres ressourcer til at skabe social værdi: økonomisk vækst, kunst, journalistik etc.
– betingelse for en fri presse

forsvar 1. Det er vel ok at sprede data hvis, der er givet informeret samtykke

Véliz 2022
nej, vi kender ikke konsekvenserne

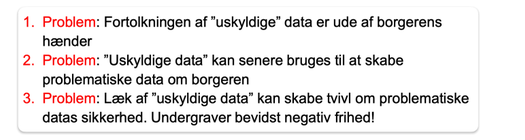
1. Problem: Fortolkningen af "uskyldige" data er ude af borgerens hænder
2. Problem: "Uskyldige data" kan senere bruges til at skabe problematiske data om borgeren
3. Problem: Læk af "uskyldige data" kan skabe tvivl om problematiske datas sikkerhed. Undergraver bevidst negativ frihed!

forsvar 2. intet at skjule - intet problem

Det omvendte 11. bud:
"det må gerne blive opdaget, hvis det ikke gør noget,
(Aka. the nothing to hide argument)

forsvar 3: Overvågning skader ikke, hvis data aldrig tilgås
Skal først bruges når det er relevant

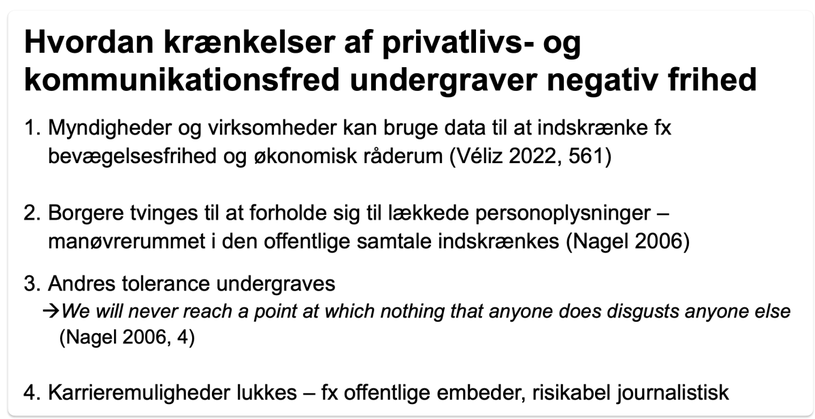
Hvordan krænkelser af privatlivs- og kommunikationsfred undergraver negativ frihed

1. Myndigheder og virksomheder kan bruge data til at indskrænke fx bevægelsesfrihed og økonomisk råderum (Véliz 2022, 561)
2. Borgere tvinges til at forholde sig til lækkede personoplysninger – manøvrerummet i den offentlige samtale indskrænkes (Nagel 2006)
3. Andres tolerance undergraves
   →*We will never reach a point at which nothing that anyone does disgusts anyone else* (Nagel 2006, 4)
4. Karrieremuligheder lukkes – fx offentlige embeder, risikabel journalistik

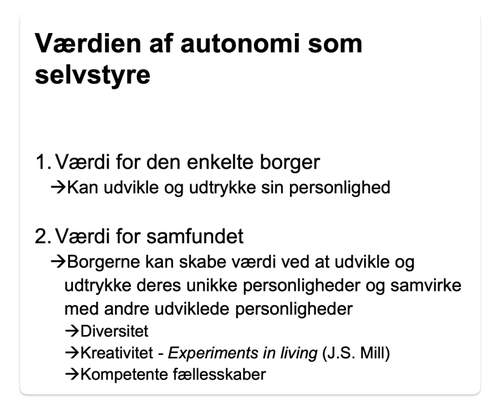
Værdien af autonomi som selvstyre

1. Værdi for den enkelte borger
   →Kan udvikle og udtrykke sin personlighed
2. Værdi for samfundet
   →Borgerne kan skabe værdi ved at udvikle og udtrykke deres unikke personligheder og samvirke med andre udviklede personligheder
   →Diversitet
   →Kreativitet - *Experiments in living* (J.S. Mill)
   →Kompetente fællesskaber

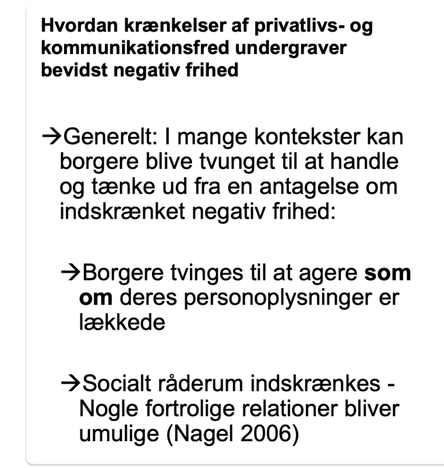
Hvordan krænkelser af privatlivs- og kommunikationsfred undergraver bevidst negativ frihed

→Generelt: I mange kontekster kan borgere blive tvunget til at handle og tænke ud fra en antagelse om indskrænket negativ frihed:

→Borgere tvinges til at agere **som om** deres personoplysninger er lækkede

→Socialt råderum indskrænkes - Nogle fortrolige relationer bliver umulige (Nagel 2006)

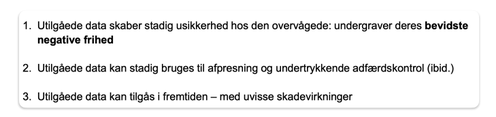
1. Utilgåede data skaber stadig usikkerhed hos den overvågede: undergraver deres **bevidste negative frihed**
2. Utilgåede data kan stadig bruges til afpresning og undertrykkende adfærdskontrol (ibid.)
3. Utilgåede data kan tilgås i fremtiden – med uvisse skadevirkninger

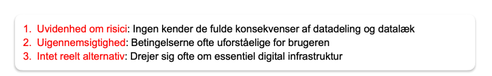
1. Uvidenhed om risici: Ingen kender de fulde konsekvenser af datadeling og datalæk
2. Uigennemsigtighed: Betingelserne ofte uforståelige for brugeren
3. Intet reelt alternativ: Drejer sig ofte om essentiel digital infrastruktur

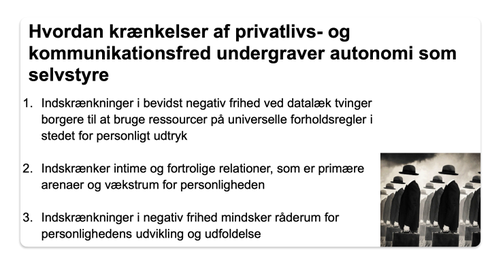
Hvordan krænkelser af privatlivs- og kommunikationsfred undergraver autonomi som selvstyre

1. Indskrænkninger i bevidst negativ frihed ved datalæk tvinger borgere til at bruge ressourcer på universelle forholdsregler i stedet for personligt udtryk
2. Indskrænker intime og fortrolige relationer, som er primære arenaer og vækstrum for personligheden
3. Indskrænkninger i negativ frihed mindsker råderum for personlighedens udvikling og udfoldelse

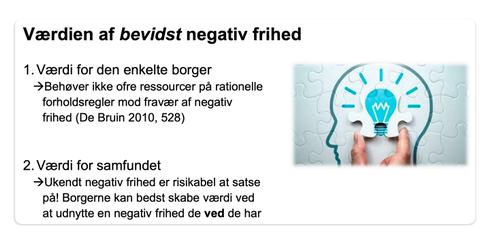
Værdien af *bevidst* negativ frihed

1. Værdi for den enkelte borger
   →Behøver ikke ofre ressourcer på rationelle forholdsregler mod fravær af negativ frihed (De Bruin 2010, 528)
2. Værdi for samfundet
   →Ukendt negativ frihed er risikabel at satse på! Borgerne kan bedst skabe værdi ved at udnytte en negativ frihed de **ved** de har

AI502 - 6

AI og paternalistisk lovgivning

SDU

AI502 - 25 - 6 - paternalisme
PDF-dokument · 1,7 MB

Paternalisme
når A anvender (direkte/indirekte) over for B når:
1. A ser bort fra B's selvstændige præferencer/vurderinger
2. A gør dette af hensyn til B's velfærd/interesser (som A ser dem)

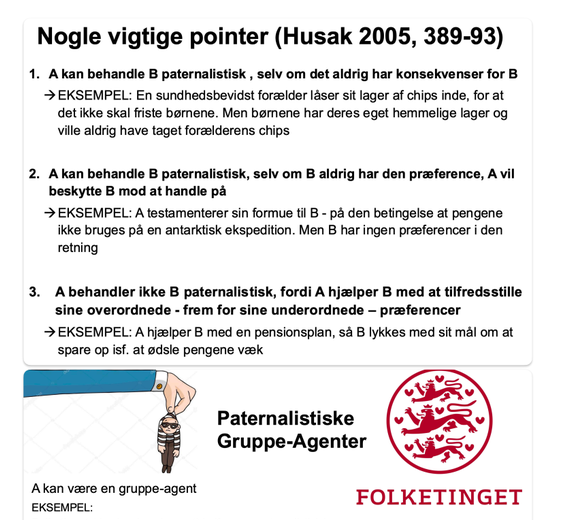
Nogle vigtige pointer (Husak 2005, 389-93)

1. **A kan behandle B paternalistisk , selv om det aldrig har konsekvenser for B**
   →EKSEMPEL: En sundhedsbevidst forælder låser sit lager af chips inde, for at det ikke skal friste børnene. Men børnene har deres eget hemmelige lager og ville aldrig have taget forælderens chips
2. **A kan behandle B paternalistisk, selv om B aldrig har den præference, A vil beskytte B mod at handle på**
   →EKSEMPEL: A testamenterer sin formue til B - på den betingelse at pengene ikke bruges på en antarktisk ekspedition. Men B har ingen præferencer i den retning
3. **A behandler ikke B paternalistisk, fordi A hjælper B med at tilfredsstille sine overordnede - frem for sine underordnede – præferencer**
   →EKSEMPEL: A hjælper B med en pensionsplan, så B lykkes med sit mål om at spare op isf. at ødsle pengene væk

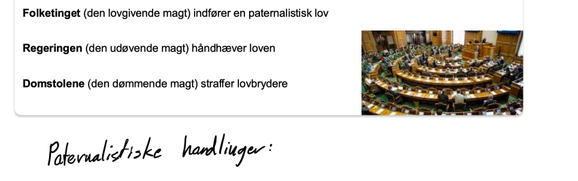
Paternalistiske Gruppe-Agenter

FOLKETINGET

A kan være en gruppe-agent
EKSEMPEL:
Folketinget (den lovgivende magt) indfører en paternalistisk lov
Regeringen (den udøvende magt) håndhæver loven
Domstolene (den dømmende magt) straffer lovbrydere

Paternalistiske handlinger:
1. udtryk for velvilje og omsorg
2. udtryk for disrespekt for frihed & myndighed

individets frihed skal være ukrænkelig
hvis en stat krænker dette er det moralsk uacceptabelt

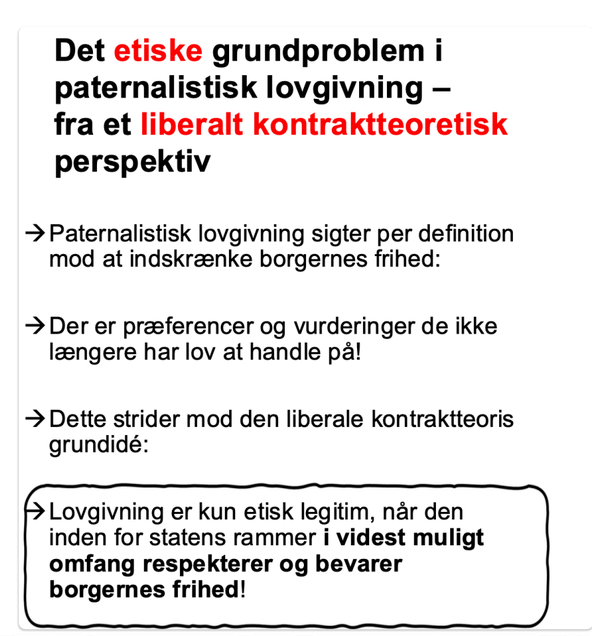
Det etiske grundproblem i paternalistisk lovgivning – fra et liberalt kontraktteoretisk perspektiv

→Paternalistisk lovgivning sigter per definition mod at indskrænke borgernes frihed:

→Der er præferencer og vurderinger de ikke længere har lov at handle på!

→Dette strider mod den liberale kontraktteoris grundidé:

→Lovgivning er kun etisk legitim, når den inden for statens rammer **i videst muligt omfang respekterer og bevarer borgernes frihed**!

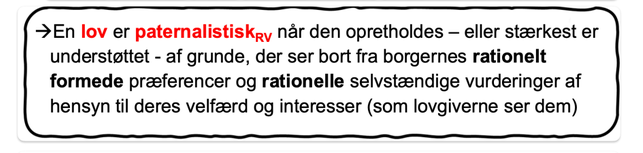
→En **lov** er **paternalistisk**$_{RV}$ når den opretholdes – eller stærkest er understøttet - af grunde, der ser bort fra borgernes **rationelt formede** præferencer og **rationelle** selvstændige vurderinger af hensyn til deres velfærd og interesser (som lovgiverne ser dem)

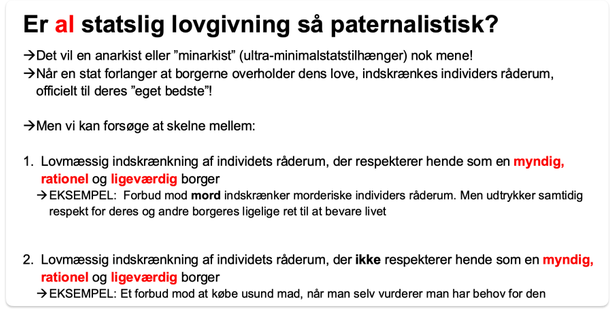
Er al statslig lovgivning så paternalistisk?

→Det vil en anarkist eller "minarkist" (ultra-minimalstatstilhænger) nok mene!
→Når en stat forlanger at borgerne overholder dens love, indskrænkes individers råderum, officielt til deres "eget bedste"!

→Men vi kan forsøge at skelne mellem:

1. Lovmæssig indskrænkning af individets råderum, der respekterer hende som en **myndig, rationel** og **ligeværdig** borger
   →EKSEMPEL: Forbud mod **mord** indskrænker morderiske individers råderum. Men udtrykker samtidig respekt for deres og andre borgeres ligelige ret til at bevare livet
2. Lovmæssig indskrænkning af individets råderum, der **ikke** respekterer hende som en **myndig, rationel** og **ligeværdig** borger
   →EKSEMPEL: Et forbud mod at købe usund mad, når man selv vurderer man har behov for den

Elementer i hård paternalisme
1. evne til at overskue sine valgmuligheder (power of recognition)
2. evne til at vælge blandt sine muligheder på basis af veloverveiede grunde (power of discrimination)
3. evne til at fastholde og gennemføre sine valg (power of satisfaction)

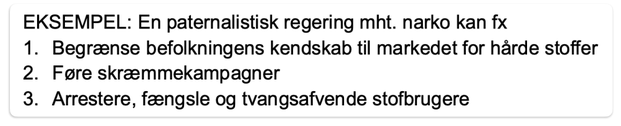
EKSEMPEL: En paternalistisk regering mht. narko kan fx
1. Begrænse befolkningens kendskab til markedet for hårde stoffer
2. Føre skræmmekampagner
3. Arrestere, fængsle og tvangsafvende stofbrugere

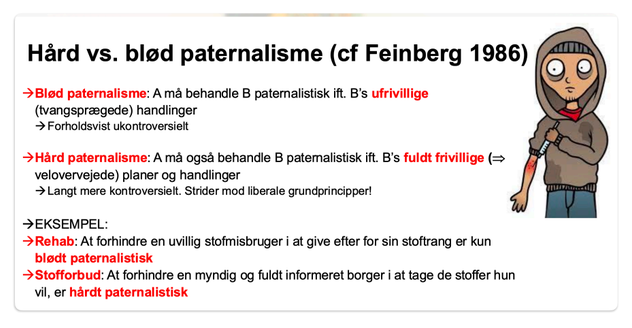
Hård vs. blød paternalisme (cf Feinberg 1986)

→**Blød paternalisme**: A må behandle B paternalistisk ift. B's **ufrivillige** (tvangsprægede) handlinger
→Forholdsvist ukontroversielt

→**Hård paternalisme**: A må også behandle B paternalistisk ift. B's **fuldt frivillige** (⇒ veloverveiede) planer og handlinger
→Langt mere kontroversielt. Strider mod liberale grundprincipper!

→EKSEMPEL:
→**Rehab**: At forhindre en uvillig stofmisbruger i at give efter for sin stoftrang er kun **blødt paternalistisk**
→**Stofforbud**: At forhindre en myndig og fuldt informeret borger i at tage de stoffer hun vil, er **hårdt paternalistisk**